

Metody Optymalizacji

Projekt: CVRPTW

Jakub Wasilewski 263852

19 czerwca 2026

Spis treści

1	Sformułowanie zadania	3
2	Sposób rozwiązywania zadania	3
2.1	Kodowanie rozwiązania	3
2.2	Ocena rozwiązania	3
3	Implementacja	4
3.1	Algorytm ewolucyjny	4
3.2	Operatory niestandardowe	4
4	Pliki wejściowe	5
5	Procedura badawcza	5
5.1	Strojenie parametrów	5
5.2	Porównanie końcowe	6
5.3	Środowisko obliczeniowe	6
6	Strojenie parametrów – potok ops_on	7
6.1	Faza 1: rozmiar populacji	7
6.2	Faza 2: operator krzyżowania	7
6.3	Faza 3: prawdopodobieństwo krzyżowania (Xp)	8
6.4	Faza 4: prawdopodobieństwo mutacji (Mp)	9
6.5	Faza 5: rozmiar turnieju (turSize)	10
6.6	Faza 6: prawdopodobieństwo Repair (REPAIRp)	11
6.7	Faza 7: prawdopodobieństwo OptimizeTracks (OPTp)	12
6.8	Faza 8: prawdopodobieństwo RedistributeLocations (REDISTp)	13
6.9	Najlepsze parametry – potok ops_on	14
7	Strojenie parametrów – potok ops_off	14
7.1	Faza 1: rozmiar populacji	15
7.2	Faza 2: operator krzyżowania	15
7.3	Faza 3: prawdopodobieństwo krzyżowania	16
7.4	Faza 4: prawdopodobieństwo mutacji	17
7.5	Faza 5: rozmiar turnieju	17
7.6	Najlepsze parametry – potok ops_off	18
8	Porównanie końcowe	18
8.1	Przebiegi algorytmu	20

9	Analiza wyników i wnioski	21
9.1	Wpływ operatorów niestandardowych	21
9.2	Kluczowe obserwacje	22
9.3	Porównanie z najlepszymi znanymi rozwiązaniami (BKS)	22
9.4	Ograniczenia badania	23

1 Sformułowanie zadania

Celem zadania była implementacja i eksperymentalne zbadanie algorytmu ewolucyjnego (EA) dla *Capacitated Vehicle Routing Problem with Time Windows* (CVRPTW) – pojemnościowego problemu wyznaczania tras pojazdów z oknami czasowymi.

W CVRPTW rozpatrywano n klientów i flotę pojazdów o jednakowej pojemności Q , startujących i kończących trasę w jednym magazynie (depot). Każdy klient $i \in \{1, \dots, n\}$ charakteryzowany był przez:

- lokalizację (x_i, y_i) ,
- zapotrzebowanie $d_i > 0$,
- okno czasowe $[e_i, l_i]$ – najwcześniejszy i najpóźniejszy dopuszczalny czas obsługi,
- czas obsługi s_i .

Celem było znalezienie zestawu tras minimalizujących **łączną długość tras** przy zachowaniu ograniczeń pojemnościowych i okien czasowych. Jeśli pojazd przybywa do klienta przed e_i , czeka bez kary. Przekroczenie l_i karane jest proporcjonalnie do opóźnienia (miękkie ograniczenie).

2 Sposób rozwiązywania zadania

2.1 Kodowanie rozwiązania

Rozwiązanie kodowane jest jako permutacja liczb całkowitych o długości $L = \text{SIZE} + \text{MAX_VEHICLES} - 1$.

- Wartości $0 \dots \text{SIZE} - 1$ oznaczają klientów.
- Wartości $\geq \text{SIZE}$ są separatorami tras („powrót do bazy”).

Dla $n = 5$ klientów i 3 pojazdów ($L = 7$) przykładowy genom:

$$x = [3, 1, \mathbf{5}, 0, 4, \mathbf{6}, 2]$$

odpowiada trasom: $\{3, 1\} \rightarrow \text{baza} \rightarrow \{0, 4\} \rightarrow \text{baza} \rightarrow \{2\}$. Separatory ≥ 5 są ignorowane pod względem tożsamości – liczy się tylko ich pozycja w genomie; wartości klientów muszą tworzyć permutację $\{0, \dots, n - 1\}$.

Dla instancji Solomona (100 klientów, 25 pojazdów): $L = 100 + 25 - 1 = 124$.

2.2 Ocena rozwiązania

Funkcja `EstimateSolution` symuluje przejazd każdego pojazdu od lewej do prawej w genomie:

1. Pojazd startuje z bazy ($t = 0$, ładunek = 0).
2. Po napotkaniu separatora: reset czasu i ładunku (powrót do bazy).
3. Po napotkaniu klienta i : sprawdzany jest ładunek (jeśli d_i przekracza pozostałą pojemność, automatycznie wraca do bazy), aktualizowany jest czas przyjazdu, doliczana kara za spóźnienie, dodawany czas obsługi s_i .
4. Koszt całkowity = suma odległości euklidesowych + suma kar.

Kary:

- Spóźnienie ($t > l_i$): $\text{LATE_ARRIVAL_PENALTY} = 0,01 \times (t - l_i)$.
- Wczesne przybycie ($t < e_i$): brak kary, pojazd czeka.

Miękkie ograniczenia umożliwiają algorytmowi eksplorację przestrzeni rozwiązań niekoniecznie dopuszczalnych, co ułatwia przejście przez obszary zakazane.

3 Implementacja

3.1 Algorytm ewolucyjny

Zaimplementowano klasyczny algorytm ewolucyjny z następującymi składowymi:

Inicjalizacja Populacja P losowych permutacji generowana metodą Fisher-Yates ($\mathcal{O}(n)$).

Selekcja Turniejowa: losuje się $k = \text{turSize}$ osobników i wybiera tego z najmniejszą wartością funkcji celu. Mała wartość k zwiększa presję selekcyjną łagodnie; duża szybko eliminuje słabych osobników.

Krzyżowanie Stosowane z prawdopodobieństwem Xp . Dostępne operatory:

- **OX** (*Ordered Crossover*) – kopiuje ciągły segment z P1, uzupełnia brakujące geny w kolejności z P2. Zachowuje względną kolejność.
- **PMX** (*Partially Mapped Crossover*) – definiuje odwzorowanie między segmentami rodziców i przenosi je na potomka.
- **CX** (*Cycle Crossover*) – identyfikuje cykle pozycjonalne i kopiuje geny cyklicznie z P1 i P2.

Mutacja Stosowana z prawdopodobieństwem Mp :

- **SWAP** – zamiana dwóch losowych genów.
- **INVERSE** – odwrócenie losowego segmentu genomu.

Elitaryzm elitesNum najlepszych osobników przechodzi do nowej populacji bez zmian – gwarantuje monotoniczność najlepszego rozwiązania.

Nowa populacja Generowana przez selekcję + krzyżowanie + mutacja dla pozostałych $P - \text{elitesNum}$ miejsc.

3.2 Operatory niestandardowe

Po standardowej mutacji z określonymi prawdopodobieństwami stosowane są trzy dodatkowe operatory, działające na poziomie tras:

Repair (naprawa okien czasowych): Operator przechodzi genom i identyfikuje klientów, dla których czas przyjazdu przekracza l_i (spóźnienie). Klientów naruszających okno czasowe wycina z bieżącej pozycji i próbuje wstawić ich w inne miejsce genomu, gdzie ograniczenie jest spełnione. Jeśli żadna pozycja nie eliminuje naruszenia, klient wstawiany jest w miejsce minimalizującym karę. Operator poprawia dopuszczalność rozwiązania bez ingerencji w ogólną strukturę podziału na trasy.

Parametr: REPAIRp – prawdopodobieństwo zastosowania operatora.

OptimizeTracks (lokalna optymalizacja kolejności w trasie): Dla każdej trasy z osobna wykonuje zachłanne wstawianie (*greedy insertion*): buduje trasę od nowa, w każdym kroku wybierając klienta minimalizującego bieżący koszt cząstkowy. Operator nie przenosi klientów między trasami – optymalizuje wyłącznie kolejność obsługi w obrębie jednej trasy.

Parametr: OPTp – prawdopodobieństwo zastosowania operatora.

RedistributeLocations (redystrybucja klientów między trasami): Wybiera losową trasę-dawcę i losowego klienta; próbuje przenieść go na każdą możliwą pozycję w każdej innej trasie (biorcy). Akceptuje ruch, jeśli obniża łączny koszt. Operator optymalizuje podział klientów między trasy, czego nie potrafią krzyżowanie ani standardowa mutacja (operują na całym genomie).

Parametry: REDISTp – prawdopodobieństwo zastosowania; REDIST_TRIES – liczba losowanych par dawca–klient.

Kolejność stosowania: Operatory stosowane są sekwencyjnie po mutacji standardowej: RedistributeLocations → Repair → OptimizeTracks. Kolejność ma znaczenie: redystrybucja zmienia strukturę tras, naprawa eliminuje naruszenia w nowych trasach, optymalizacja dopracowuje kolejność po naprawie.

4 Pliki wejściowe

Eksperymenty przeprowadzono na instancjach z zestawu benchmarkowego Solomona (100 klientów). Zestaw Solomona dzieli się na 6 rodzin w zależności od rozmieszczenia klientów i charakteru okien czasowych:

Rodzina	Rozmieszczenie klientów	Okna czasowe
C1	klastrowe	wąskie
C2	klastrowe	szerokie
R1	losowe	wąskie
R2	losowe	szerokie
RC1	mieszane	wąskie
RC2	mieszane	szerokie

Do strojenia parametrów użyto 3 instancji (po jednej z C1, R1, RC1): **C101, R101, RC101**.

Do porównania końcowego użyto 12 instancji – po dwie z każdej rodziny: C101, C102, C201, C202, R101, R102, R201, R202, RC101, RC102, RC201, RC202.

5 Procedura badawcza

5.1 Strojenie parametrów

Strojenie przeprowadzono metodą **jednowymiarowej analizy wrażliwości** (*one-factor-at-a-time*): w każdej fazie zmieniany jest jeden parametr, pozostałe utrzymywane na wartości wybranej w poprzedniej fazie (tzw. *sequential tuning*).

Kryterium zatrzymania podczas strojenia: stały budżet $B = 300\,000$ wywołań funkcji oceny. Każda konfiguracja testowana $N = 5$ razy niezależnie.

Miary jakości stosowane w tabelach strojenia:

- Wartość dla instancji (np. kolumna **C101**) – średnia arytmetyczna wartości funkcji oceny najlepszego osobnika z ostatniej generacji, uśredniona po $N = 5$ niezależnych uruchomieniach.

- **OVERALL** – średnia arytmetyczna wartości z trzech instancji strojenia (C101, R101, RC101); używana jako kryterium wyboru zwycięzcy fazy.

Odchylenie standardowe nie jest wyznaczane podczas strojenia ze względu na małą liczbę powtórzeń ($N = 5$) – służy ono wyłącznie do selekcji wariantów, nie do wnioskowania statystycznego.

Przeprowadzono **dwa niezależne potoki strojenia**:

- **ops_on**: EA z włączonymi operatorami niestandardowymi – 8 faz.
- **ops_off**: EA bazowy bez operatorów niestandardowych – 5 faz.

Każdy potok startuje z ustalonej **konfiguracji bazowej**, od której odchylany jest jeden parametr na raz. Konfiguracje bazowe obu potoków przedstawia tabela 1.

Tabela 1: Konfiguracje bazowe obu potoków strojenia

Parametr	ops_on (bazowa)	ops_off (bazowa)
popSize	50	50
Krzyżowanie	OX	OX
Xp	75%	75%
Mp	25%	25%
turSize	2	2
Mutacja	SWAP	SWAP
elitesNum	1	1
REPAIRp	70%	0%
OPTp	30%	0%
REDISTp	80%	0%

W każdej fazie testowane są warianty różniące się *tylko* strojonym parametrem; zwycięski wariant staje się nową bazą dla kolejnej fazy.

Niezależne potoki zapewniają *fair comparison*: każdy wariant dobiera swoje optymalne parametry, a nie tylko parametry dopasowane do drugiego.

5.2 Porównanie końcowe

Porównanie przeprowadzono na 12 instancjach Solomona, $N = 5$ niezależnych uruchomień każdej konfiguracji, z kryterium zatrzymania opartym na stagnacji: algorytm zatrzymuje się, gdy przez 10 000 kolejnych pokoleń nie nastąpiła poprawa najlepszego rozwiązania (twardy limit: 1 000 000 wywołań funkcji celu).

5.3 Środowisko obliczeniowe


Implementacja w C++17, skompilowana z flagami `-O3 -march=native -flto -ffast-math`. Generator losowy: `std::mt19937` (Mersenne Twister).

6 Strojenie parametrów – potok ops_on

6.1 Faza 1: rozmiar populacji

Tabela 2: Faza 1 (ops_on) – strojenie popSize ($B = 300\,000$, $N = 5$)

popSize	C101	R101	RC101	OVERALL
10	1642	1425	1772	1613
20	1707	1401	1663	1591
50	1515	1341	1620	1492
100	1652	1443	1769	1622




Rysunek 1: Faza 1 (ops_on): wpływ rozmiaru populacji na średni koszt finalny.

Wnioski: Populacja 50 wygrała we wszystkich instancjach. Mała populacja (10, 20) oznacza mało pokoleń przy stałym budżecie – operatory niestandardowe nie mają czasu na dopracowanie tras. Zbyt duża (100) spowalnia konwergencję. Przyjęto popSize=50.

6.2 Faza 2: operator krzyżowania

Tabela 3: Faza 2 (ops_on) – typ krzyżowania ($N = 5$)

Operator	C101	R101	RC101	OVERALL
OX	1634	1392	1600	1542
PMX	1723	1496	1737	1652
CX	2017	1728	2088	1944




Rysunek 2: Faza 2 (ops_on): porównanie operatorów krzyżowania.

Wnioski: OX wygrał wyraźnie. CX wypadł najgorzej – operator cykliczny zachowuje pozycje absolutne, co przy problemach permutacyjnych z ważną kolejnością względną jest niekorzystne. OX zachowuje kolejność względną klientów z jednego rodzica, co jest semantycznie spójne z kodowaniem tras. Przyjęto OX.

6.3 Faza 3: prawdopodobieństwo krzyżowania (X_p)

Tabela 4: Faza 3 (ops_on) – strojenie X_p ($N = 5$)

X_p	C101	R101	RC101	OVERALL
50%	1734	1469	1783	1662
75%	1576	1351	1626	1518
90%	1586	1396	1703	1562




Rysunek 3: Faza 3 (ops_on): wpływ prawdopodobieństwa krzyżowania.

Wnioski: $X_p=75\%$ daje najlepsze wyniki. Zbyt rzadkie krzyżowanie (50%) ogranicza rekombinację – algorytm zachowuje się zbyt podobnie do prostej mutacji. Zbyt częste (90%) niszczy dopracowane trasy szybciej, niż operatory naprawcze zdążają je odbudować. Przyjęto $X_p=75$.

6.4 Faza 4: prawdopodobieństwo mutacji (M_p)

Tabela 5: Faza 4 (ops_on) – strojenie M_p ($N = 5$)

M_p	C101	R101	RC101	OVERALL
10%	2084	1677	2103	1954
25%	1561	1362	1629	1517
40%	2006	1659	2002	1889




Rysunek 4: Faza 4 (ops_on): wpływ prawdopodobieństwa mutacji.

Wnioski: $Mp=25\%$ wygrało we wszystkich instancjach z dużym marginesem. Niska mutacja (10%) powoduje zbyt szybką utratę różnorodności populacji. Wysoka (40%) losowo niszczy strukturę tras – operator Repair i OptimizeTracks muszą naprawiać nie tylko błędy wynikające z krzyżowania, ale też ze zbyt agresywnej mutacji, co przekracza ich możliwości w dostępnym budżecie. Przyjęto $Mp=25$.

6.5 Faza 5: rozmiar turnieju (turSize)

Tabela 6: Faza 5 (ops_on) – strojenie turSize ($N = 5$)

turSize	C101	R101	RC101	OVERALL
2	1593	1357	1637	1529
3	2043	1722	1995	1920
5	2335	1825	2309	2157




Rysunek 5: Faza 5 (ops_on): wpływ rozmiaru turnieju.

Wnioski: Mały turniej ($k = 2$) wygrał wyraźnie. Duży turniej ($k = 5$) powoduje zbyt dużą presję selekcyjną – populacja szybko ulega homogenizacji wokół lokalnego optimum, a operatory niestandardowe nie mogą wygenerować dostatecznie różnorodnych rozwiązań startowych. Przyjęto `turSize=2`.

6.6 Faza 6: prawdopodobieństwo Repair (REPAIRp)

Tabela 7: Faza 6 (ops_on) – strojenie REPAIRp ($N = 5$)

REPAIRp	C101	R101	RC101	OVERALL
30%	1583	1411	1622	1539
70%	1680	1420	1609	1570
100%	1663	1353	1680	1565




Rysunek 6: Faza 6 (ops_on): wpływ prawdopodobieństwa operatora Repair.

Wnioski: Niższe REPAIRp (30%) okazuje się lepsze – operator Repair jest kosztowny obliczeniowo (skanuje cały genom); zbyt częste jego stosowanie zmniejsza liczbę pokoleń w budżecie. Przyjęto REPAIRp=30.

6.7 Faza 7: prawdopodobieństwo OptimizeTracks (OPTp)

Tabela 8: Faza 7 (ops_on) – strojenie OPTp ($N = 5$)

OPTp	C101	R101	RC101	OVERALL
10%	1614	1401	1631	1548
30%	1586	1390	1719	1565
60%	1623	1393	1675	1563




Rysunek 7: Faza 7 (ops_on): wpływ prawdopodobieństwa operatora OptimizeTracks.

Wnioski: Wyniki faz 6 i 7 są zbliżone – różnice mieszczą się w granicach zmienności statystycznej przy $N = 5$. OPT=10% wygrało globalnie; podobnie jak Repair, zbyt częste stosowanie OptimizeTracks kosztuje pokolenia. Przyjęto OPTp=10.

6.8 Faza 8: prawdopodobieństwo RedistributeLocations (REDISTp)

Tabela 9: Faza 8 (ops_on) – strojenie REDISTp ($N = 5$)

REDISTp	C101	R101	RC101	OVERALL
30%	1594	1391	1685	1557
80%	1652	1351	1711	1572
100%	1607	1409	1644	1553



Rysunek 8: Faza 8 (ops_on): wpływ prawdopodobieństwa operatora RedistributeLocations.

Wnioski: REDISTp=100% wygrało ogólnie – RedistributeLocations jest lżejszy obliczeniowo niż Repair/OPT, więc stosowanie go przy każdej mutacji nie nadmiernie obciąża budżetu. Przyjęto REDISTp=100.

6.9 Najlepsze parametry – potok ops_on

Tabela 10: Optymalne parametry EA z operatorami niestandardowymi

Parametr	Wartość
popSize	50
Krzyżowanie	OX
Xp	75%
Mp	25%
turSize	2
elitesNum	1
REPAIRp	30%
OPTp	10%
REDISTp	100%


7 Strojenie parametrów – potok ops_off

Potok ops_off stroi parametry EA bazowego (bez operatorów niestandardowych) w 5 fazach. Każda faza startuje od wartości wybranej w poprzedniej fazie.

7.1 Faza 1: rozmiar populacji

Tabela 11: Faza 1 (ops_off) – strojenie popSize ($B = 300\,000$, $N = 5$)

popSize	C101	R101	RC101	OVERALL
10	1964	1624	1976	1855
20	1700	1464	1896	1687
50	1635	1443	1695	1591
100	1864	1545	1933	1780




Rysunek 9: Faza 1 (ops_off): wpływ rozmiaru populacji.

7.2 Faza 2: operator krzyżowania

Tabela 12: Faza 2 (ops_off) – typ krzyżowania ($N = 5$)

Operator	C101	R101	RC101	OVERALL
OX	1709	1399	1754	1621
PMX	2002	1624	2060	1895
CX	2297	1866	2393	2185




Rysunek 10: Faza 2 (ops_off): porównanie operatorów krzyżowania.

7.3 Faza 3: prawdopodobieństwo krzyżowania

Tabela 13: Faza 3 (ops_off) – strojenie X_p ($N = 5$)

X_p	C101	R101	RC101	OVERALL
50%	2012	1592	2051	1885
75%	1673	1412	1796	1627
90%	1878	1497	1920	1765




Rysunek 11: Faza 3 (ops_off): wpływ prawdopodobieństwa krzyżowania.

7.4 Faza 4: prawdopodobieństwo mutacji

Tabela 14: Faza 4 (ops_off) – strojenie M_p ($N = 5$)

M_p	C101	R101	RC101	OVERALL
10%	2522	2047	2621	2397
25%	1656	1429	1723	1603
40%	2670	2184	2773	2542




Rysunek 12: Faza 4 (ops_off): wpływ prawdopodobieństwa mutacji.

Wnioski: W wariancie bez operatorów niestandardowych wrażliwość na M_p jest znacznie większa – wynik przy $M_p=10\%$ i $M_p=40\%$ jest dramatycznie gorszy niż przy 25% . Bez mechanizmów naprawczych zbyt mała mutacja powoduje utknięcie, a zbyt duża niszczy rozwiązania nieodwracalnie.

7.5 Faza 5: rozmiar turnieju

Tabela 15: Faza 5 (ops_off) – strojenie turSize ($N = 5$)

turSize	C101	R101	RC101	OVERALL
2	1655	1451	1738	1615
3	2630	2112	2730	2491
5	3419	2752	3560	3244



Rysunek 13: Faza 5 (ops_off): wpływ rozmiaru turnieju.

Wnioski: Rozmiar turnieju ma w variancie bez operatorów efekt katastrofalny przy $k > 2$. Duża presja selekcyjna bez mechanizmów naprawczych prowadzi do szybkiej degeneracji populacji.

7.6 Najlepsze parametry – potok ops_off

Tabela 16: Optymalne parametry EA bazowego (bez operatorów niestandardowych)

Parametr	Wartość
popSize	50
Krzyżowanie	OX
Xp	75%
Mp	25%
turSize	2
elitesNum	1


Oba potoki niezależnie wybrały identyczne parametry bazowe, co potwierdza ich robustność i wskazuje, że wybory te nie są artefaktem obecności lub braku operatorów niestandardowych.

8 Porównanie końcowe


Porównanie przeprowadzono z optymalnymi konfiguracjami obu potoków na 12 instancjach Solomona. Kryterium zatrzymania: brak poprawy przez 10 000 kolejnych pokoleń lub limit 1 000 000 wywołań funkcji celu. $N = 10$ niezależnych uruchomień na instancję.

Tabela 17: Wyniki porównania końcowego – średni koszt, odchylenie standardowe i najlepszy wynik z 10 uruchomień

Instancja	ops_on			ops_off			Zwycięzca
	avg	std	best	avg	std	best	
C101	1459	76	1344	1432	101	1312	ops_off (−1,9%)
C102	1391	42	1327	1348	67	1231	ops_off (−3,1%)
C201	1063	44	988	1131	72	1027	ops_on (−6,0%)
C202	1096	80	1008	1122	75	1027	ops_on (−2,3%)
R101	1262	45	1193	1255	53	1200	ops_off (−0,6%)
R102	1229	64	1154	1231	36	1187	ops_on (−0,2%)
R201	1227	38	1150	1184	31	1137	ops_off (−3,5%)
R202	1141	47	1063	1164	51	1108	ops_on (−2,0%)
RC101	1548	91	1400	1505	67	1403	ops_off (−2,8%)
RC102	1473	51	1366	1526	107	1347	ops_on (−3,5%)
RC201	1377	45	1325	1315	73	1208	ops_off (−4,5%)
RC202	1286	38	1234	1262	65	1175	ops_off (−1,9%)
OVERALL	1296	–	–	1290	–	–	ops_off (−0,5%)




Rysunek 14: Porównanie końcowe: ops_on vs ops_off dla 12 instancji Solomona. Liczby między słupkami pokazują bezwzględną różnicę kosztów.




Rysunek 15: Porównanie końcowe pogrupowane wg rodziny instancji. Procenty pokazują względną różnicę ops_on względem ops_off.


8.1 Przebiegi algorytmu



Rysunek 16: Przebieg EA dla instancji C101 – uśredniony przebieg 10 uruchomień.



Rysunek 17: Przebieg EA dla instancji R101.



Rysunek 18: Przebieg EA dla instancji RC101.

9 Analiza wyników i wnioski

9.1 Wpływ operatorów niestandardowych

EA bazowy (ops_off) osiągnął globalnie nieco lepszy wynik niż EA z operatorami (ops_on): średni koszt OVERALL 1290 vs 1296 (różnica 0,5%). ops_off wygrał na 7 z 12 instancji. Wyniki są jednak niejednorodne i zależą silnie od rodziny instancji:

- **C1 (clustered, wąskie TW):** ops_off wygrywa obie instancje (1432 vs 1459 dla C101, 1348 vs 1391 dla C102). Wąskie okna czasowe ograniczają skuteczność operatora Repair – naruszenia są trudne do naprawienia bez cofania całego przydziału klientów do tras.
- **C2 (clustered, szerokie TW):** ops_on wygrywa obie instancje wyraźnie (o 6% dla C201: 1063 vs 1131). Szerokie okna dają operatorom swobodę działania – OptimizeTracks i Redi-

tributeLocations mogą efektywnie przekształcać trasy w klastrach bez ryzyka naruszenia TW.

- **R1/R2 (random):** wyniki mieszane – każda konfiguracja wygrywa po 2 instancje. Różnice są małe (0,2–3,5%), co sugeruje, że operatory nie dają znaczącej przewagi na losowo rozmieszczonych klientach.
- **RC1/RC2 (mixed):** ops_off wygrywa 3 z 4 instancji (RC101, RC201, RC202), ops_on wygrywa tylko RC102. Największa przewaga ops_off widoczna dla RC201 (1315 vs 1377, 4,5%).

9.2 Kluczowe obserwacje

1. **Operatory niestandardowe nie poprawiają wyników globalnie.** ops_off wygrywa na 7 z 12 instancji i osiąga nieco lepszy OVERALL (1290 vs 1296, różnica 0,5%). Wynik jest zaskakujący i wskazuje, że operatory nie zawsze pomagają – ich skuteczność zależy od struktury instancji. ops_on wygrywa wyraźnie tylko na rodzinie C2 (szerokie okna).
2. **Parametry EA są niemal identyczne w obu potokach.** popSize=50, OX, Xp=75%, Mp=25%, turSize=2 okazały się optymalne niezależnie od obecności operatorów niestandardowych. Wskazuje to na robustność tych wyborów dla CVRPTW.
3. **Wrażliwość na turSize jest dramatycznie większa bez operatorów.** Przy ops_off turSize=3 daje wynik o 54% gorszy od turSize=2, podczas gdy przy ops_on ta różnica wynosi 25%. Operatory niestandardowe pełnią rolę bufora zabezpieczającego przed degeneracją populacji przy dużej presji selekcyjnej.
4. **Operatory niestandardowe preferują niskie prawdopodobieństwa.** Optymalne wartości to REPAIRp=30%, OPTp=10%, REDISTp=100%. Dwa pierwsze operatory są kosztowne obliczeniowo – zbyt częste stosowanie konsumuje budżet bez proporcjonalnej poprawy jakości. RedistributeLocations jest lżejszy i można go stosować zawsze.
5. **Przebiegi zbieżności pokazują różnicę w charakterze eksploracji.** ops_on zbiega szybciej w pierwszych generacjach (operatory natychmiast naprawiają błędy), ale ops_off może dogonić przy długim horyzoncie – szczególnie widoczne dla C101 i R101.

9.3 Porównanie z najlepszymi znanymi rozwiązaniami (BKS)

BKS (*Best Known Solution* – najlepsze znane rozwiązanie) to najlepszy wynik uzyskany kiedykolwiek dla danej instancji benchmarkowej przez dowolny algorytm opisany w literaturze naukowej. Wartości BKS dla benchmarku Solomona publikowane są i aktualizowane przez SINTEF – norweski instytut badań przemysłowych prowadzący oficjalny ranking wyników dla VRPTW (sintef.no/top/vrptw).

Wartości BKS wymagają **pełnej dopuszczalności** – wszystkie okna czasowe muszą być spełnione bez naruszeń. W niniejszej implementacji zastosowano miękkie ograniczenia z małą karą (LATE_ARRIVAL_PENALTY = 0,01), co pozwala algorytmowi na naruszanie okien czasowych kosztem minimalnej kary.

Tabela 18: Porównanie z BKS – wyniki obu konfiguracji

Instancja	BKS	ops_on avg	gap (%)	ops_off avg	gap (%)
C101	828,94	1459	+76,0%	1432	+72,7%
C102	828,94	1391	+67,8%	1348	+62,6%
C201	591,56	1063	+79,7%	1131	+91,2%
C202	591,56	1096	+85,3%	1122	+89,7%
R101	1650,80	1262	−23,5%	1255	−23,9%
R102	1486,12	1229	−17,3%	1231	−17,2%
R201	1252,37	1227	−2,0%	1184	−5,5%
R202	1191,70	1141	−4,3%	1164	−2,3%
RC101	1696,95	1548	−8,8%	1505	−11,3%
RC102	1554,75	1473	−5,2%	1526	−1,8%
RC201	1406,94	1377	−2,1%	1315	−6,5%
RC202	1365,65	1286	−5,8%	1262	−7,6%

Interpretacja wyników względem BKS:

- **Instancje C (klastrowe):** nasze wyniki są o 63–91% gorsze od BKS. Instancje C mają wąskie okna czasowe – algorytm ze słabą karą za spóźnienie nie jest wystarczająco motywowany do ich respektowania i generuje trasy o mniejszym dystansie kosztem wielu naruszeń.
- **Instancje R i RC:** nasze wyniki są *poniżej* BKS (do −24%). Jest to bezpośredni dowód naruszania okien czasowych – minimalna odległość dopuszczalnych tras dla R101 wynosi 1650,80, więc wynik 1262 jest fizycznie niemożliwy bez naruszeń. Mała kara (0,01) sprawia, że algorytm ignoruje okna czasowe i minimalizuje tylko dystans.

Podsumowanie: zastosowana penalizacja jest zbyt mała, aby wymusić dopuszczalność. Porównanie bezpośrednie z BKS jest dlatego niemożliwe. Wartością eksperymentu jest porównanie *względne* ops_on vs ops_off w identycznych warunkach.

9.4 Ograniczenia badania

- Zastosowana penalizacja (współczynnik 0,01 za spóźnienie) jest zbyt mała, by zapewnić dopuszczalność rozwiązań. Wyniki R/RC poniżej BKS jednoznacznie wskazują na naruszenia okien czasowych.
- Liczba powtórzeń $N = 5$ daje ograniczoną moc statystyczną – różnice poniżej 2% mogą nie być istotne statystycznie.
- Strojenie metodą one-factor-at-a-time nie gwarantuje globalnego optimum w przestrzeni parametrów – interakcje między parametrami nie są badane.